Desenvolvimento de um Classificador de Diagnóstico com Machine Learning para Identificação de Fatores de Risco Associados à Reprovação Escolar

Carlos Magno Bernardino da Silva[1]*; Heloísa Helena Dias Martins Proença[2]

[1] Professor da Rede Pública de Ensino. Rua Domiciano Lopes de Faria,282 –João Braz; 36576-192, Viçosa, Minas Gerais, Brasil.
[2] Universidade de São Paulo. Orientadora do MBA. Avenida Pádua Dias, 11 – São Dimas, 13418-900 Piracicaba, São Paulo, Brasil
*autor correspondente: mabnobs.silva@gmail.com

Desenvolvimento de um Classificador de Diagnóstico com Machine Learning para Identificação de Fatores de Risco Associados à Reprovação Escolar

Resumo

A educação brasileira enfrenta desafios significativos, intensificados pela pandemia de COVID-19, que provocaram retrocessos no aprendizado e aumento das taxas de evasão e reprovação escolar. Nesse cenário, a identificação precoce de alunos em risco é fundamental para a implementação de ações pedagógicas preventivas, evitando o agravamento contínuo desses problemas. Este trabalho teve como objetivo desenvolver um classificador de diagnóstico, baseado em técnicas de machine learning, para identificar fatores de risco associados à reprovação escolar em uma escola da rede pública de Minas Gerais. A metodologia envolveu a coleta e o pré-processamento de dados de históricos escolares, contemplando notas e faltas anuais. Foram comparados três algoritmos de classificação: Regressão Logística, Random Forest e XGBoost. Para lidar com o desbalanceamento de classes, aplicou-se a técnica de subamostragem (undersampling). Os resultados demonstraram a superioridade do modelo XGBoost, que alcançou uma Área Sob a Curva (AUC) de 0,959, precisão de 0,855 e revocação (recall) de 0,897, indicando alta capacidade de identificar corretamente alunos em risco de reprovação. Esses achados reforçam a importância do absenteísmo e do desempenho acadêmico como variáveis preditoras. Apesar da boa performance, o estudo reconhece limitações decorrentes do uso de dados de uma única instituição, o que restringe a generalização dos resultados. Recomenda-se, em pesquisas futuras, a inclusão de variáveis socioeconômicas e comportamentais, ampliando a robustez do modelo. Conclui-se que a aplicação de ciência de dados na educação pode oferecer instrumentos eficazes de apoio à tomada de decisão, auxiliando gestores e educadores na adoção de intervenções direcionadas para reduzir a reprovação e promover a permanência escolar.
Palavras-chave: aprendizado de máquina; reprovação escolar; XGBoost

Introdução

A educação brasileira mostrou um regresso significativo após a pandemia, chegando, de acordo com a UNICEF (2021), a retroceder o equivalente a duas décadas. Essa regressão traz à tona a fragilidade do ensino do nosso país e evidencia a necessidade de medidas urgentes para amenizar os problemas presentes na educação brasileira, buscando criar um progresso contínuo que nos permita avançar rumo a uma educação de qualidade.

A transição para o ensino remoto durante a pandemia evidenciou desigualdades, com mais de 3 milhões de estudantes sem acesso à internet e, dentre esses, muitos enfrentaram dificuldades devido à precariedade do serviço contratado, além da falta de equipamentos adequados para utilização das plataformas didáticas (DataSenado, 2022). Além disso, a falta de estrutura nas residências, como locais de estudo apropriados, a sobrecarga de tarefas domésticas e o desânimo gerado pelo isolamento social impactaram negativamente o desempenho escolar. Isso resultou em um aprendizado deficiente e um aumento expressivo nos índices de evasão escolar, que cresceram 128% entre 2020 e 2021 (INESC, 2022).

Nesse cenário, estudos aprofundados sobre o desempenho individual dos alunos tornam-se ferramentas estratégicas para a identificação precoce de dificuldades de aprendizagem e risco de evasão. A literatura aponta que a reprovação escolar é um dos

principais fatores associados ao abandono (Rumberger & Lim, 2008), e que intervenções preventivas, quando aplicadas de forma direcionada, podem reduzir significativamente esse risco (Silva Filho & Araújo, 2017). Assim, compreender padrões de desempenho e fatores preditores de insucesso escolar é fundamental para subsidiar ações pedagógicas mais assertivas.

Este trabalho propõe o desenvolvimento de um modelo supervisionado de aprendizado de máquina, treinado a partir de históricos escolares de alunos da rede pública, abrangendo desde o Ensino Fundamental I até o Ensino Médio. O objetivo é identificar padrões e variáveis que estejam fortemente associados à reprovação, permitindo que gestores e educadores adotem medidas preventivas antes que a defasagem se torne irreversível. A relevância deste estudo reside na possibilidade de oferecer um instrumento de apoio à tomada de decisão, contribuindo para a permanência e o sucesso escolar.

A relevância desta pesquisa justifica-se pela urgência em desenvolver estratégias baseadas em evidências para enfrentar os desafios educacionais agravados pela pandemia. Ao identificar padrões que antecedem a reprovação, este estudo poderá contribuir para a formulação de políticas e práticas pedagógicas mais eficazes, alinhadas às recomendações de organismos internacionais como a International Commission on The Future of Education (2020), que enfatizam a importância do uso de dados e tecnologias para promover a equidade e a qualidade na educação.

Material e Métodos

Para alcançar objetivos os estabelecidos para a pesquisa, foi adotada uma abordagem quantitativa, com coleta de dados secundários provenientes de uma escola da rede pública, seguindo integralmente as normas da Lei Geral de Proteção de Dados Pessoais (LGPD) (Lei nº 13.709/2018). Foram realizadas análises estatísticas descritivas e aplicados modelos de aprendizado de máquina, seguindo um fluxo de trabalho de ciência de dados dividido em quatro etapas: (1) pré-processamento e limpeza dos dados; (2) engenharia de atributos; (3) Desenvolvimento do Classificador de Diagnóstico; (4) avaliação de desempenho.

Todo o processo de processamento, análise e modelagem dos dados foi conduzido utilizando a linguagem de programação Python, com o suporte de um conjunto de bibliotecas científicas consolidadas. A manipulação e limpeza dos dados foram realizadas com a biblioteca Pandas; a modelagem e o pré-processing com Scikit-learn e XGBoost; o tratamento de classes desbalanceadas com Imbalanced-learn; e a geração de gráficos com Matplotlib e Seaborn.

Coleta e Caracterização dos Dados

Os dados utilizados neste estudo foram extraídos dos arquivos escolares de uma escola da rede pública de ensino do estado de Minas Gerais. A coleta foi realizada de forma manual, consultando registros digitalizados a partir do ano de 2012, marco inicial da digitalização dos documentos na instituição. A base de dados consolidada abrange informações como notas por disciplina, total de faltas anuais, série, nível de ensino e a situação final do aluno em cada ano letivo. Em conformidade com a Lei Geral de Proteção de Dados (LGPD – Lei nº 13.709/2018), informações de identificação pessoal, como o nome do aluno, foram removidas nas etapas subsequentes, utilizando-se um identificador numérico [ID] anônimo como chave primária.

Pre-Processamento e Limpeza dos Dados

As informações foram organizadas em uma base de dados única utilizando a biblioteca Pandas, ferramenta central para todo o processo de manipulação e limpeza. A coluna Aproveitamento possuía dados desiguais, que foram padronizados de forma que notas conceituais (ex.: “A”, “B”, “C”, “OTM”) passassem a representar escalas numéricas (0–100). Notas em escala de 0–10 foram normalizadas para a mesma escala.

O tratamento de valores nulos (NaN) na coluna Total_Faltas_Minutos foi realizado utilizando a média das faltas do próprio aluno. Essa técnica é preferível à imputação pela média global, pois preserva a variabilidade individual dos dados (Han; Kamber; Pei, 2011). Nos casos em que o aluno não apresentava nenhum registro de falta, os valores foram preenchidos com a média geral.

Foi realizada uma limpeza para remoção de caracteres indesejados em todas as colunas, além do tratamento de dados categóricos por meio do mapeamento de conceitos, onde o conceito “A” foi associado a 100, “B” a 75, “C” a 60, “D” a 50. Valores como “ÓTIMO” e “MB” também foram convertidos para valores numéricos. Notas mais antigas, que estavam em escalas de 1 a 10, foram padronizadas para se alinharem à escala padrão de 0 a 100. O tratamento dos dados ausentes [NaN] nas colunas de faltas foi realizado com a média individual do aluno, conforme técnica de pré-processamento descrita por McKinney (2018). Algumas colunas que continham informações pessoais foram removidas, a fim de manter conformidade com a LGPD.

Engenharia de Atributos

Após a limpeza dos dados, foi criada uma nova variável ("feature") que unia as colunas Série e Nível_Ensino em uma única variável categórica, agora chamada de Serie_Nivel (ex.: "3º Ano F" para Fundamental e "3º Ano M" para Ensino Médio), diferenciando, portanto, anos escolares homônimos.

A variável alvo dependente (Target) do modelo foi construída com base nas notas de corte usualmente estabelecidas pela educação básica brasileira. Pontuações iguais ou superiores a 60 foram classificadas como "Aprovado", enquanto notas iguais ou inferiores a 59,9 foram classificadas como "Reprovado". Com base nesse conceito, foi criada a coluna Status_Anual, atribuindo a definição "Reprovado de Ano" a qualquer aluno que apresentasse ao menos um registro de reprovação em qualquer disciplina daquele ano letivo. Por fim, a coluna Target foi convertida para o formato binário, em que o valor 1 representa "Reprovado no Ano" e o valor 0, "Aprovado no Ano".

A transformação final das features categóricas (Serie_Nivel e Disciplina) em formato numérico foi realizada com a função get_dummies da biblioteca Pandas, que implementa a técnica de One-Hot Encoding. Essa transformação realizada a partir do pressuposto que aprendizado de máquina operam, em sua maioria, com dados numéricos, o que facilita o processamento e a modelagem preditiva. Além disso, a binarização da variável de saída permite a aplicação de técnicas de classificação supervisionada, como regressão logística, árvores de decisão e random forest, utilizadas em problemas com desfechos dicotômicos (Kotsiantis et al., 2007).

Desenvolvimento do Classificador de Diagnóstico

A seleção do algoritmo de machine learning foi realizada com base em uma avaliação comparativa entre três modelos implementados com as bibliotecas Scikit-learn e XGBoost, buscando-se alta acurácia preditiva e capacidade de extração de fatores determinantes para a reprovação. Foram testados três algoritmos com diferentes abordagens e níveis de complexidade: a Regressão Logística, utilizada como modelo de base para estabelecer uma linha de performance inicial; o Random Forest (Breiman, 2001); e o XGBoost (Chen & Guestrin, 2016), ambos modelos de ensemble amplamente utilizados na literatura por sua capacidade de modelar relações não-lineares.

As features numéricas (Aproveitamento e Total_Faltas_Minutos) foram padronizadas com a técnica StandardScaler. A padronização, ou Z-score, transforma cada valor de uma variável subtraindo a média (μ) e dividindo pelo desvio padrão (σ), conforme a form. (1).

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

em que: z é o valor padronizado, x é o valor original, μ é a média e σ é o desvio padrão da feature.

Para lidar com o desbalanceamento entre as classes, foram testadas três estratégias distintas: o ajuste de pesos de classe (class_weight ou scale_pos_weight), a superamostragem sintética [SMOTE] (Chawla et al., 2002) e a subamostragem aleatória (undersampling). A escolha da técnica mais adequada foi feita com base em um experimento de validação cruzada, conforme recomendações de He & Garcia (2009) para problemas com classes desproporcionais.

A performance dos modelos foi avaliada em um conjunto de teste, utilizando-se métricas derivadas da Matriz de Confusão, que permitem avaliar de forma abrangente a performance de classificadores binários, tabulando os acertos e erros do modelo em quatro categorias: Verdadeiros Positivos (TP), Verdadeiros Negativos (TN), Falsos Positivos (FP) e Falsos Negativos (FN). Dentre essas métricas, duas foram priorizadas. A primeira é a Precisão (Precision), que mede a confiabilidade dos alertas gerados, sendo calculada pela form. (2).

$$\text{Precisão} = \frac{TP}{\text{TP} + \text{FP}} \tag{2}$$

em que: TP (Verdadeiro Positivo) representa os alunos reprovados que o modelo previu corretamente como reprovados; FP (Falso Positivo), os alunos aprovados que o modelo previu incorretamente como reprovados;

A segunda métrica fundamental é a Revocação (Recall), que mede a capacidade de detecção do modelo, ou seja, sua habilidade de encontrar os alunos que de fato estão em risco. Sua definição matemática é apresentada na form. (3).

$$\text{Revocação (Recall)} = \frac{\text{TP}}{TP + FN} \tag{3}$$

onde: TP (Verdadeiro Positivo) representa os alunos reprovados que o modelo previu corretamente como reprovados; FP (Falso Positivo), os alunos aprovados que o modelo previu incorretamente como reprovados; e FN (Falso Negativo), os alunos reprovados que o modelo previu incorretamente como aprovados.

Resultado e Discussão

A análise dos resultados foi conduzida utilizando-se um ambiente computacional baseado na linguagem de programação Python, suportado por bibliotecas como Pandas, Scikit-learn e XGBoost. Inicialmente, os dados brutos foram submetidos a um processo de

tratamento e engenharia de features, também em Python, que foi responsável por limpar, transformar e enriquecer a base de dados, culminando na construção da variável alvo (Target) para a classificação. O código também estruturou o processo de validação cruzada e a avaliação comparativa dos diferentes algoritmos de machine learning.

Posteriormente, os resultados obtidos, tanto da análise exploratória quanto da performance dos modelos, foram visualizados através das bibliotecas Matplotlib e Seaborn. A criação de gráficos estatísticos, tabelas de performance e análises de interpretabilidade diretamente a partir do ambiente de análise garantiu a integridade e a rastreabilidade dos resultados. A combinação do Python para o processamento de dados e a modelagem estatística, juntamente com suas bibliotecas de visualização, proporcionou uma base sólida para a discussão e as conclusões apresentadas a seguir.

Análise Exploratória dos Dados

A análise inicial do conjunto de dados após a etapa inicial de limpeza, trouxe importantes informações sobre o perfil dos estudantes analisados. A destruição das notas finais e das faltas, visualizado nos histogramas (Figura 1), apresenta diferentes características. A distribuição do “Notas Finais” (Gráfico à esquerda), indica que esta variável apresenta uma concentrada distribuição entre os valores de 60 a 100, com um pico próximo ao valor máximo. Isso indica que a maior parte dos alunos apresentam desempenho escolar satisfatório, apresentando alta taxa de aprovação.

Já no gráfico à direita, é visível uma distribuição assimétrica (right-skewed) da variável Total de Faltas em Minutos. A maioria dos alunos apresenta um baixo coeficiente de ausência, concentrando nas faixas iniciais do eixo X. No entanto, fica evidenciado uma cauda longa que se estende continuamente no eixo das abscissas, indicando a presença de um pequeno grupo de estudantes com taxa elevada de ausência. Essa é uma característica relevante, pois faltas excessivas estão frequentemente associadas à reprovação e evasão escolar.

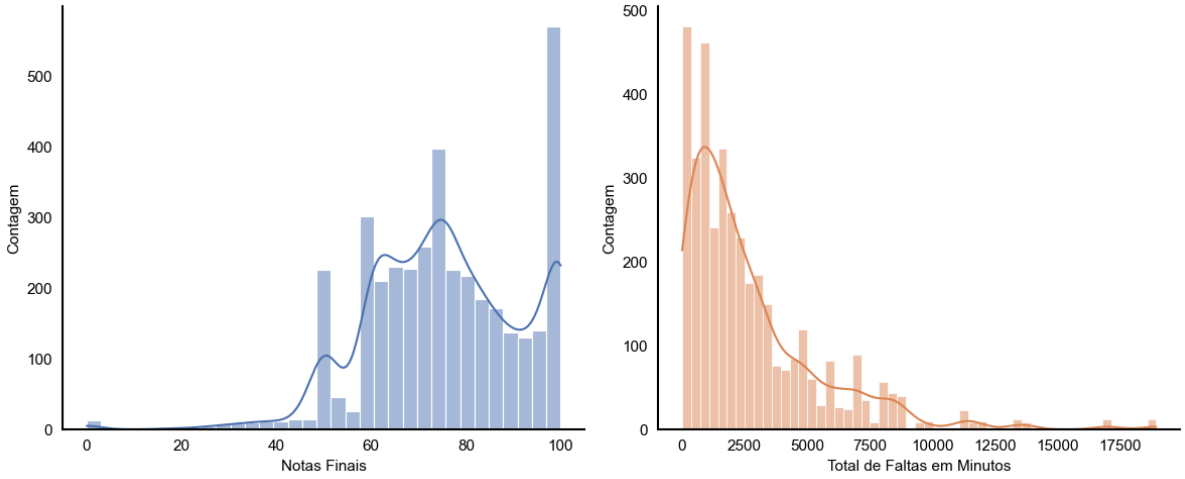

Figura 1. Distribuição das variáveis contínuas: (a) Notas Finais dos alunos e (b) Total de Faltas em Minutos por ano letivo

Fonte: Resultados originais da pesquisa

Nota: “Contagem” refere-se ao número total amostras

A assimetria observada na distribuição de faltas também reforça a necessidade de técnicas de balanceamento e padronização durante o pré-processamento dos dados, como a aplicação do StandardScaler e o ajuste do hiperparâmetro class_weight = ‘balanced’.

A relação das duas variáveis com o desempenho escolar do aluno é evidente no box plots (Figura 2). É observado uma separação clara entre o grupo de estudantes aprovados e reprovados. Os registros de aprovação apresentam, na mediana, notas superiores em relação aos reprovados. Por conseguinte, as faltas evidenciam uma mediana similar entre o grupo dos aprovados e reprovados, no entanto, a variabilidade das faltas no grupo de reprovados é muito maior, indicando que o absenteísmo elevado é um fator distintivo desse grupo. Esses padrões reforçam a correlação entre desempenho, frequência e reprovação escolar, conforme apontado por Rumberger & Lim (2008), que destacam a importância da presença como fator crucial ao sucesso acadêmico.

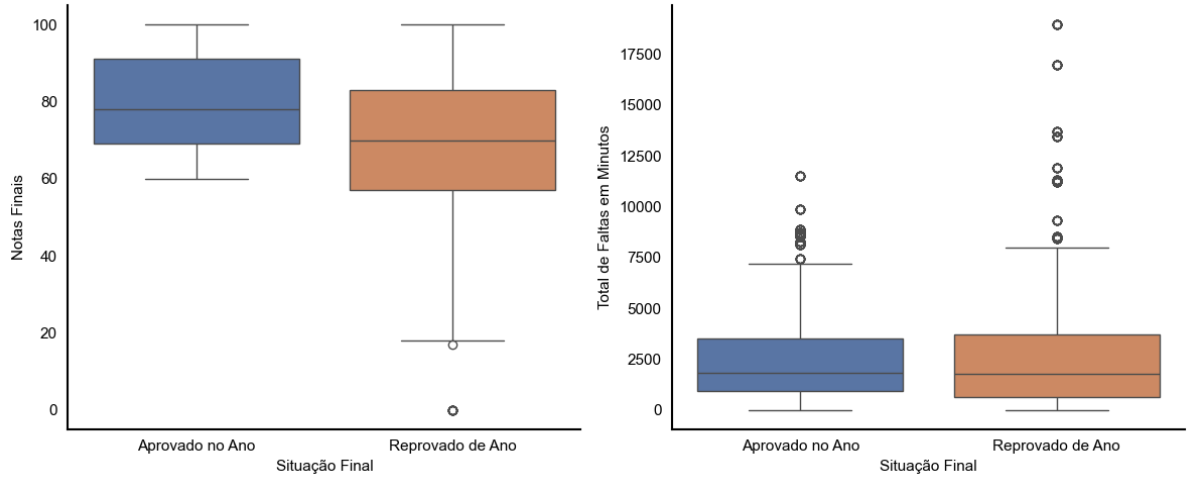

Figura 2. Análise comparativa das distribuições de (a) Notas Finais e (b) Total de Faltas em Minutos, estratificadas pela Situação Final do aluno no ano letivo
Fonte: Resultados originais da pesquisa

Comparação de Técnicas de Balanceamento

Antes da aplicação dos modelos preditivos, foi usado a abordagem de ajuste de pesos *(class_weight = 'balanced')* para lidar com o desbalanceamento entre as classes 'Aprovado' e 'Reprovado'. Para isso foram testadas três abordagens: ajuste de pesos via class_weight='balanced', "oversampling" com SMOTE [Synthetic minority Over-sampling Technique] e Undersampling com remoção aleatória da classe majoritária. A Tabela 1 apresenta os resultados médios obtidos com cada técnica, utilizando o classificador Random Forest como base.

Tabela 1 – Tabela Comparativa Final de Modelos e Técnicas (Média de 5 Rodadas)

Ano Escolar	Técnica	Recall Médio	Precisão Média	F1-Score Médio	AUC Médio
Random Forest	Class_Weight	0.631± 0.039	0.752± 0.026	0.685 ± 0.016	0.849 ± 0.004
	Smote	0.678 ± 0.021	0.720 ± 0.026	0.698 ± 0.007	0.839 ± 0.005
	Undersampling	0.716 ± 0.029	0.696 ± 0.018	0.705 ± 0.007	0.840 ± 0.007
Regressão Logistica	Class_Weight	0.630 ± 0.043	0.575 ± 0.015	0.601 ± 0.023	0.716 ± 0.017
	Smote	0.621 ± 0.038	0.574 ± 0.014	0.596 ± 0.017	0.716 ± 0.015
	Undersampling	0.626 ± 0.043	0.565 ± 0.015	0.593 ± 0.022	0.712 ± 0.018

XGBoost	Class_Weight	0.884 ± 0.029	0.885 ± 0.011	0.884 ± 0.016	0.966 ± 0.006
	Smote	0.863 ± 0.024	0.874 ± 0.015	0.868 ± 0.006	0.958 ± 0.005
	Undersampling	0.897 ± 0.018	0.855 ± 0.023	0.875 ± 0.011	0.959 ± 0.006

Fonte: Resultados originais da pesquisa

A técnica de subamostragem (*u*ndersampling) apresentou maior grau de confiabilidade nos modelos de ensemble (Random Forest e XGBoost), exibindo a Revocação (Recall) média mais eficiente para detecção de alunos em risco de reprovação. Essa decisão está alinhada com a literatura, que recomenda o uso de técnicas de balanceamento em problemas educacionais com classes desproporcionais (He & Garcia, 2009; Kotsiantis et al., 2007).

Avaliação dos Classificadores de Diagnóstico

Com os dados balanceados por meio de undersampling, foram testados três modelos preditivos: Regressão Logistica, Random Forest e XGBoost. A avaliação foi realizada por meio de validação cruzada k-fold com cinco rodadas. A escolha e avaliação dos modelos seguiram recomendações metodológicas amplamente discutidas por Fávero & Belfiore (2024). Para avaliar a performance dos modelos preditivos, foram utilizadas métricas clássicas de classificação binária, como *recall*, *precisão*, *F1-score* e *AUC*. Os modelos foram treinados e avaliados em um conjunto de teste composto por 1141 registros (representando a performance de um aluno em uma disciplina para um ano letivo). A Tabela 2 apresenta os resultados médios obtidos pelos três modelos testados: Regressão Logística, Random Forest e XGBoost.

Tabela 2 – Tabela Comparativa Final de Modelos e Técnicas (Média de 5 Rodadas)

Classe	Recall Médio	Precisão	F1-Score	AUC Médio
Regressão Logística	0.626 ± 0.043	0.565 ± 0.015	0.593 ± 0.022	0.712 ± 0.018
Random Forest	0.716 ± 0.029	0.696 ± 0.018	0.705 ± 0.007	0.840 ± 0.007
XGBoost	0.897 ± 0.018	0.855 ± 0.023	0.875 ± 0.011	0.959 ± 0.006

Fonte: Resultados originais da pesquisa

O modelo XGBoost apresentou desempenho superior em todas as métricas. O alto recall (0,897) e AUC (0,959) demonstra excelente capacidade discriminativa. A curva ROC (Figura 3), posicionada significativamente acima da diagonal de referência, indica que o classificador possui alta sensibilidade e especificidade. A forma da curva, com inclinação

acentuada e aproximação ao canto superior esquerdo, sugere que o modelo é capaz de distinguir com precisão entre alunos aprovados e reprovados em diferentes limiares de decisão.

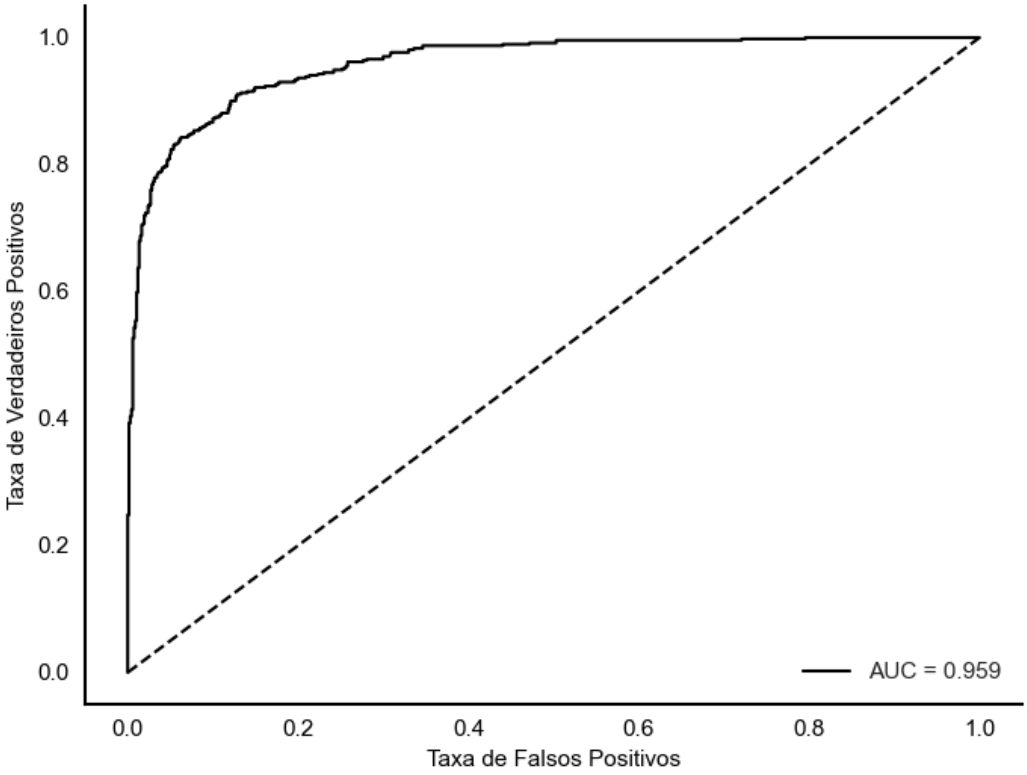

Figura 3. Curva Característica de Operação do Receptor (ROC) para o modelo XGBoost final, com o valor da Área Sob a Curva (AUC) de 0.959.
Fonte: Resultados originais da pesquisa

Embora esses valores indiquem excelentes valores como AUC = 0,959, há á possiblidade de “overfitting”. O uso de apenas duas variáveis relevantes (nota final e total de faltas) pode ter facilitado a separação entre as classes, gerando um modelo excessivamente ajustado ao padrão da escola analisada. Esse risco é reforçado pelo fato de os dados serem provenientes de uma única instituição, o que limita a capacidade de generalização do classificador. A literatura recomenda que modelos educacionais sejam testados em múltiplos contextos para garantir robustez (Romero & Ventura, 2010; Baker & Inventado, 2014).

Para aumentar a confiabilidade do modelo, seria recomendado adicionar variáveis que capturem uma maior dimensão do cenário educacional brasileiro, como fatores socioeconômicos (renda familiar, escolaridade dos responsáveis; avalição individual dos professores sobre o comportamento do aluno. Além disso, o uso de notas por disciplina, em vez da média anual, permitiria identificar dificuldades específicas em áreas do conhecimento, juntamente com a participação em programas de recuperação ou reforço escolar.

Análise da Matriz de Confusão

Para uma visualização simplificada dos tipos de acertos e erros do modelo, foi utilizado a Matriz de Confusão (Figura 4). No total de 471 casos de reprovação no conjunto teste, 411 foram corretamente identificados pelo modelo (Verdadeiros Negativos), sendo classificados como 'Reprovado', enquanto 60 (Falsos Negativos) não foram detectados e classificados incorretamente como "Aprovado". Esse grupo representa aproximadamente 12,7% dos alunos reprovados que não foram detectados pelo classificador, embora essa seja uma taxa relativamente baixa, em termos operacionais seria necessária uma otimização ainda maior do modelo a fim de evitar a omissão de alunos que realmente necessitam de intervenção pedagógica

Em relação aos 670 casos de aprovação presentes no conjunto de teste, 602 foram corretamente identificados pelo modelo como 'Aprovado' (Verdadeiros Positivos). Por outro lado, 68 alunos aprovados foram classificados incorretamente como 'Reprovado' (Falsos Positivos), o que representa aproximadamente 10,1% dos alunos aprovados que foram sinalizados indevidamente. Nesse caso o erro operacionalmente é menos prejudicial, uma vez que a consequência prática é a sinalização de um aluno aprovado como potencialmente em risco, o que pode levar à aplicação de medidas pedagógicas preventivas que, embora desnecessárias, não comprometem diretamente o percurso acadêmico do estudante.

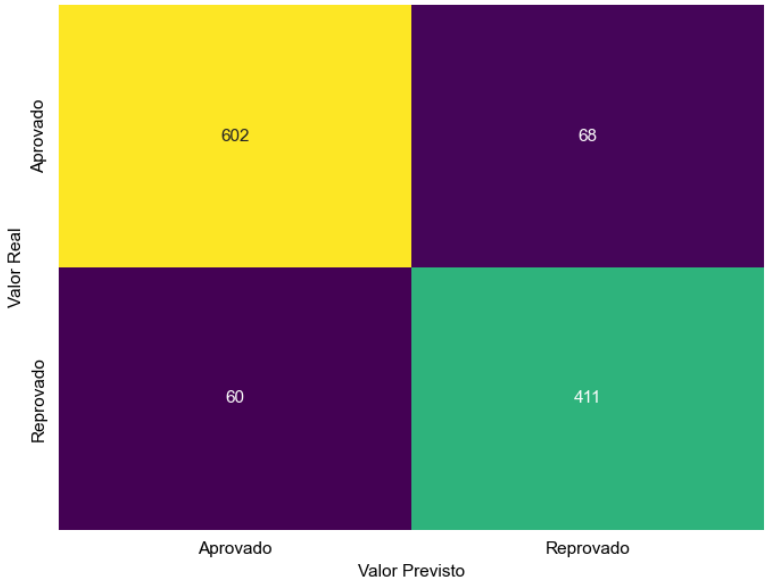

Figura 4. Matriz de Confusão da performance do modelo XGBoost final no conjunto de teste, detalhando os acertos (diagonal principal) e erros (fora da diagonal)
Fonte: Resultados originais da pesquisa

A análise conjunta da matriz de confusão revela que o classificador apresenta equilíbrio entre sensibilidade e especificidade, com destaque para sua capacidade de identificar corretamente os alunos em risco de reprovação.

Considerações Finais

Este trabalho se propôs a desenvolver um classificador de machine learning para identificar fatores de risco associados à reprovação de alunos, utilizando um extenso histórico de dados de uma escola da rede pública. A avaliação de múltiplos algoritmos levou há desenvolvimento de um modelo XGBoost, capaz de classificar para aquela instituição o risco de reprovação anual com uma AUC de 0.959, demonstrando que os padrões de desempenho com as variáveis estabelecidas podem ser aprendidos com alta precisão.

O estudo vigente descobriu que variantes de desempenho acadêmico e absenteísmo são cruciais para o resultado no ano letivo do aluno. O modelo final demonstrou uma alta capacidade de detecção (Revocação de 89.7%) e grande confiabilidade em seus alertas (Precisão de 85.5%), demonstrando ser uma ferramenta de diagnóstico eficiente.

É importante, no entanto, ressaltar as dificuldades presentes para a realização desse trabalho. O primeiro grande empecilho residiu na obtenção e tratamento dos dados. A extração manual dos registros, um a um, foi um processo trabalhoso que, por si demonstra de certa forma os desafios de se trabalhar com dados educacionais no Brasil.

Esta dificuldade é, em grande parte, um sintoma de sistemas de gestão escolar que, embora funcionais para o arquivamento de documentos, mostram-se muitas vezes desatualizados e rudimentares sob a ótica da análise de dados. Tais sistemas não são projetados para a extração de informações em lote ou para a interoperabilidade, aumentando a propensão de erros na coleta desses dados.

O estudo apresentou uma limitação de escopo, pois foi utilizado apenas dados de uma instituição. Embora o modelo funcione perfeitamente para a realidade desta escola, não pode ser considerado um modelo generalista, não sendo possível afirmar sua funcionabilidade em outras organizações.

Portanto, este trabalho atingiu seu objetivo, entregando um classificador eficiente. Mais do que isso, ele demonstra o potencial da utilização de dados como ferramenta de gestão pedagógica. Para futuros trabalhos, recomenda-se a validação do modelo em outras instituições e, pincipalmente a inclusão de novas features (como dados socioeconômicos e avaliações comportamentais dos alunos) para a criação de um classificador mais holístico.

Referências

BAKER, R. S.; INVENTADO, P. S. Educational data mining and learning analytics. In: Spector, J. M.; Ifenthaler, D.; Sampson, D.; Yang, L. (eds.). Handbook of Research on Educational Communications and Technology. 4th ed. Springer, 2014, p. 385–400.

BREIMAN, L. Random forests. Machine Learning, v. 45, n. 1, p. 5–32, 2001.

BRASIL. Senado Federal. Impactos da pandemia na educação no Brasil. DataSenado, 2022. Disponível em: https://www12.senado.leg.br/institucional/datasenado/materias/pesquisas/impactos-da-pandemia-na-educacao-no-brasil. . Acesso em: 17 mar. 2025.

CHAWLA, N. V.; BOWYER, K. W.; HALL, L. O.; KEGELMEYER, W. P. SMOTE: synthetic minority over-sampling technique. Journal of Artificial Intelligence Research, v. 16, p. 321–357, 2002.

CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), p. 785–794, 2016.

FÁVERO, L. P.; BELFIORE, P. Manual de análise de dados: estatística e machine learning com Excel®, SPSS®, Stata®, R® e Python®. 1. ed. Atlas, São Paulo, SP, Brasil, 2024.

FUNDO DAS NAÇÕES UNIDAS PARA A INFÂNCIA (UNICEF). Cenário da exclusão escolar no Brasil: um alerta sobre os impactos da pandemia da COVID-19 na Educação. Brasília, DF: UNICEF, 2021. Disponível em: https://www.unicef.org/brazil/media/14026/file/cenario-da-exclusao-escolar-no-brasil.pdf. . Acesso em: 18 ago. 2025.

HAN, J.; KAMBER, M.; PEI, J. Data mining: concepts and techniques. 3. ed. San Francisco: Morgan Kaufmann, 2011.

HE, H.; GARCIA, E. A. Learning from imbalanced data. IEEE Transactions on Knowledge and Data Engineering, v. 21, n. 9, p. 1263–1284, 2009.

INSTITUTO DE ESTUDOS SOCIOECONÔMICOS (INESC). Abandono no ensino médio brasileiro duplicou na pandemia. 2022. Disponível em: https://inesc.org.br/abandono-no-ensino-medio-brasileiro-duplicou-na-pandemia/. . Acesso em: 17 mar. 2025.

INTERNATIONAL COMMISSION ON THE FUTURES OF EDUCATION. Education in a post-COVID world: nine ideas for public action. Paris: UNESCO, 2020.

KOTSIANTIS, S. B.; PINTELAS, P. E.; ZAHARAKI, M. A. Machine learning: a review of classification and combining techniques. Artificial Intelligence Review, v. 26, n. 3, p. 159–190, 2007.

MCKINNEY, W. Python for data analysis: data wrangling with pandas, NumPy, and IPython. 2. ed. Sebastopol: O'Reilly Media, 2018.

ROMERO, C.; VENTURA, S. Educational data mining: a review of the state of the art. IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), v. 40, n. 6, p. 601–618, 2010.

RUMBERGER, R. W.; LIM, S. Why students drop out of school: a review of 25 years of research. California Dropout Research Project Report, n. 15, 2008.

SILVA FILHO, Raimundo Barbosa; ARAÚJO, Ronaldo Marcos de Lima. Evasão e abandono escolar na educação básica no Brasil: fatores, causas e possíveis consequências. Educação Por Escrito, v. 8, n. 1, p. 35–48, 2017.